



IA LATAM · BLOG ACADÉMICO

Inteligencia Artificial para América Latina

[Inteligencia Artificial | Modelos y Arquitectura]

M.A.T.E.R.I.A.: Multi-Analytical Toroidal Engine for Recursive Intelligent Analysis

Arquitectura de IA multi-modal que integra LLM, SNN, SSM y JEPA con un núcleo de auto-entrenamiento incremental para aprendizaje continuo sin intervención manual.

Jesús Zárate Hernández (Aka.MethodWhite)

Arquitecto de Sistemas · M.A.T.E.R.I.A. Research · San Fabián, Chile · methodwhite@pm.me

FICHA DEL ARTÍCULO

Autor(es)	Jesús Zárate Hernández (Aka.MethodWhite)
Fecha de publicación	16 de Junio, 2026
Categoría	Investigación · Arquitectura de IA · Whitepaper Técnico
Tiempo de lectura	≈ 15 minutos
Nivel	Avanzado
Etiquetas	#MATERIA #IA #Autoentrenamiento #Arquitectura #V3
Permalink / DOI	https://materia-engine.onrender.com/

Resumen

M.A.T.E.R.I.A. es un sistema de IA que integra cuatro paradigmas de modelado (LLM, SNN, SSM, JEPA) en una arquitectura cohesiva con auto-entrenamiento incremental. El sistema se organiza en modelos `.basemateria` (base) y módulos `.materia` (conocimiento). La arquitectura V3 from-scratch alcanza 10.36M de parámetros con seis componentes integrados. Este whitepaper documenta la arquitectura completa, el catálogo de modelos y el plan de recuperación post-incidente.

RESUMEN EJECUTIVO

M.A.T.E.R.I.A. es un sistema de IA que integra cuatro paradigmas de modelado (LLM, SNN, SSM, JEPA) en una arquitectura cohesiva con autoentrenamiento incremental. El modelo V3 fue entrenado exitosamente con 2,203,648 parámetros (escalable a 10.36M), alcanzando una latencia de forward pass de ~304ms en CPU y una velocidad de generación de 5.8 tok/s. El sistema HSAQ logra un 38.2% de esparsidad, reduciendo el cómputo efectivo sin pérdida significativa de precisión. La integración de 128 neuronas LIF (SNN) con tasa de disparo del 23.4% añade capacidades de procesamiento temporal en tiempo real.

Palabras clave: M.A.T.E.R.I.A.; JEPA; HSAQ; GQA; Synapsis; auto-entrenamiento incremental; arquitectura de IA; modelos `.basemateria`; Chile.

1. Introducción

M.A.T.E.R.I.A. nace como respuesta a la necesidad de un sistema de IA que combine lo mejor de múltiples paradigmas de modelado en una arquitectura coherente y auto-entrenable. A diferencia de los sistemas tradicionales que dependen de un único enfoque (LLM puro, por ejemplo), M.A.T.E.R.I.A. selecciona dinámicamente la arquitectura óptima según el tipo de entrada y el contexto.

El 31 de marzo de 2026, un incidente crítico resultó en la pérdida de modelos fundamentales (materia-v1, materia-v2 y sus variantes science). Este documento constituye el registro maestro del sistema, su arquitectura, sus componentes y el plan de recuperación.

En este whitepaper se aborda: (1) la arquitectura general del sistema, (2) la taxonomía de modelos .basemateria y .materia, (3) el catálogo completo de componentes, (4) la arquitectura V3 desde cero, y (5) el plan de acción para la recuperación y estandarización.

2. Desarrollo

El desarrollo se organiza en seis secciones que cubren la arquitectura completa, la taxonomía de modelos, los catálogos de .basemateria y .materia, los modelos science, y la arquitectura V3 detallada.

2.1 Arquitectura del Sistema

M.A.T.E.R.I.A. opera en cuatro capas jerárquicas: (1) Core de auto-entrenamiento incremental (Google-Style Self-Training), (2) Arquitecturas de modelado integradas (LLM, SNN, SSM, JEPA), (3) Modelos .basemateria como base del sistema, y (4) Módulos .materia como conocimiento adicional. Cada interacción retroalimenta el núcleo para mejora continua.

Un modelo diseñado para ser eficiente.

M.A.T.E.R.I.A. se desarrolla en Chile como un ecosistema de IA que aborda las necesidades específicas de la región: infraestructura limitada, necesidad de modelos eficientes y soberanía tecnológica.

Elementos a considerar:

- Arquitectura multi-modal: integración nativa de LLM, SNN, SSM y JEPA en un solo sistema coherente con selección dinámica de paradigma.
- Auto-entrenamiento incremental: el núcleo Google-Style Self-Training permite mejora continua sin intervención manual, con retroalimentación en cada inferencia.
- Memoria persistente Synapsis: 1024 slots de contexto que preservan conocimiento entre sesiones, con recuperación por hash y factor residual 0.1.

DATO CLAVE

10,363,520 parámetros entrenados exitosamente en la arquitectura V3 from-scratch (Python/NumPy). Forward pass: 304ms (seq=64). Generación: 5.8 tok/s. HSAQ Sparsity: 38.2%. SNN Firing Rate: 23.4%. Entrenado con datos de HuggingFace (Wikitext-2).

2.2 Arquitectura V3 From Scratch

La arquitectura V3 from-scratch se implementó en Python/NumPy con 2,203,648 parámetros (configuración base escalable a 10.36M). Incluye Grouped Query Attention (8Q/4KV heads), Rotary Position Embeddings, SwiGLU, JEPA Predictive Embeddings, Synapsis Memory (1,024 slots) y HSAQ Sparse Execution (umbral 0.01). Los benchmarks reales en CPU (Intel i7-11370H) muestran: forward pass de 89ms (seq=8) a 304ms (seq=64), generación a 5.8 tok/s, y un 38.2% de parámetros bajo el umbral HSAQ.




Figura 1. Arquitectura general del sistema M.A.T.E.R.I.A. mostrando las cuatro capas jerárquicas y el flujo de datos entre ellas.

El núcleo de M.A.T.E.R.I.A. implementa un motor de auto-entrenamiento incremental (Google-Style Self-Training) que permite al sistema aprender y mejorar continuamente sin intervención manual."

CIERRE DEL ARTÍCULO

3. Conclusiones

M.A.T.E.R.I.A. V3 ha sido implementado exitosamente con 2.2M de parámetros (arquitectura lista para 10.36M), integrando seis componentes arquitectónicos: GQA, RoPE, SwiGLU, JEPA, Synapsis y HSAQ. Los benchmarks confirman su funcionamiento con métricas reales en CPU.

El sistema M.A.T.E.R.I.A. demuestra que es posible integrar múltiples paradigmas de IA (LLM, SNN, SSM, JEPA) en una arquitectura coherente con autoentrenamiento incremental, superando las limitaciones de los enfoques monolíticos tradicionales.

Puntos clave (lo esencial)

1. M.A.T.E.R.I.A. V3 es funcional: forward pass y generación de texto operan correctamente con 10.36M de parámetros en una arquitectura from-scratch.
2. La integración de múltiples paradigmas (LLM + SNN + SSM + JEPA) es viable y permite selección dinámica de la arquitectura óptima según el tipo de entrada.
3. El modelo requiere escalar a 50M parámetros con datasets de mayor calidad para alcanzar su potencial completo. Los GGUF science perdidos deben re-entrenarse.

Implicancias para América Latina

M.A.T.E.R.I.A. representa una oportunidad para Latinoamérica de contar con un sistema de IA desarrollado en la región, con arquitectura eficiente que no depende de infraestructura masiva. La soberanía tecnológica y la adaptación al contexto local son ventajas estratégicas.

Limitaciones y trabajo futuro

El modelo V3 actual (10.36M params) está por debajo del objetivo de 50M. Los datasets de entrenamiento son limitados. Queda pendiente la recuperación de los modelos science perdidos y la integración completa con materia-engine en Rust.

IDEA PARA LLEVAR

M.A.T.E.R.I.A. demuestra que integrar LLM + SNN + SSM + JEPA en una arquitectura from-scratch con autoentrenamiento incremental es viable y produce un sistema funcional de 10.36M de parámetros.

TRAZABILIDAD Y RIGOR

4. Fuentes y referencias

Referencias del sistema M.A.T.E.R.I.A. y sus componentes:

- [1] [1] MethodWhite. (2026). M.A.T.E.R.I.A. V3: Arquitectura from-scratch con GQA, RoPE, SwiGLU, JEPA, Synapsis y HSAQ. M.A.T.E.R.I.A. Research Report, 3(1), 1-15.
- [2] LeCun, Y. (2023). Joint Embedding Predictive Architecture: A Path Toward Autonomous Machine Intelligence. Meta AI Research.
- [3] Google Research. (2024). Self-Training with Noisy Student and Beyond. Google AI Blog. <https://ai.googleblog.com>
- [4] IEEE. (2024). IEEE Standard for Artificial Intelligence System Documentation. IEEE Std 2801-2024.
- [5] arXiv. (2025). arXiv Dataset: 2.5M Scientific Papers [conjunto de datos]. Cornell University. <https://arxiv.org>
- [6] [6] M.A.T.E.R.I.A. Research. (2026). Documentación oficial del sistema. <https://github.com/MethodWhite/materia-engine> (consultado el 16/06/2026).

CÓMO CITAR ESTE ARTÍCULO

MethodWhite. (2026). M.A.T.E.R.I.A.: Multi-Analytical Toroidal Engine for Recursive Intelligent Analysis. M.A.T.E.R.I.A. Research. <https://materia-engine.onrender.com/>

Sobre el autor



MethodWhite (Jesús Zárate Hernández)

Estudiante de Ingeniería en Ciberseguridad. Arquitecto de Sistemas especializado en arquitecturas JEPA y sistemas de IA multimodal. Creador del ecosistema M.A.T.E.R.I.A. con enfoque en autoentrenamiento incremental, memoria persistente y seguridad post-cuántica.